

Credit Card Fraud Detection Veri Seti ile Model Performans Değerlendirme

Ders: Veri Bilimi İçin İstatistik

Bölüm: Yapay Zekâ ve Makine Öğrenmesi

Dönem: 2025-2026 Bahar Dönemi

Proje Konusu: Credit Card Fraud Detection ile Model Performans Değerlendirme

Hazırlayan: Muhammed Ali KINALI

Öğrenci Numarası: 250121045

İçindekiler

1. Giriş
2. Veri Keşfi ve Ön İşleme
3. İstatistiksel Temeller ve Metodoloji
4. Modelleme Süreci
5. Performans Analizi
6. Hipotez Testleri ve Güven Aralıkları
7. Cross Validation ve Merkezi Limit Teoremi
8. Görselleştirmeler ve Bulgular
9. Tartışma
10. Sonuç
11. Kaynakça

1. GİRİŞ

Finansal teknolojilerin gelişmesiyle birlikte kredi kartı kullanımı dünya genelinde oldukça yaygın hale gelmiştir. Online alışveriş sistemleri, dijital bankacılık uygulamaları ve temassız ödeme teknolojileri günlük yaşamın ayrılmaz bir parçası olmuştur. Ancak bu gelişim beraberinde ciddi güvenlik problemlerini de ortaya çıkarmıştır. Özellikle kredi kartı dolandırıcılığı, hem kullanıcılar hem de finans kuruluşları açısından büyük ekonomik kayıplara neden olmaktadır.

Kredi kartı dolandırıcılığı probleminin çözülmesinde veri bilimi ve makine öğrenmesi teknikleri oldukça önemli bir yere sahiptir. Bankalar ve finans şirketleri milyonlarca işlemi manuel olarak inceleyemeyeceği için otomatik sistemlere ihtiyaç duymaktadır. Bu sistemler geçmiş işlem verilerini analiz ederek şüpheli işlemleri tespit etmeye çalışmaktadır.

Bu projede “Kaggle” platformunda yayınlanan “Credit Card Fraud Detection” veri seti kullanılarak bir makine öğrenmesi modelinin performansı istatistiksel açıdan incelenmiştir. Veri seti toplam 284.807 adet işlem içermektedir. Bu işlemlerin yalnızca çok küçük bir kısmı dolandırıcılık işlemidir. Dolayısıyla veri seti ciddi derecede dengesizdir. Bu durum gerçek dünya problemlerinde sıklıkla karşılaşılan önemli bir veri bilimi problemidir.

Projede temel amaç yalnızca bir sınıflandırma modeli oluşturmak değil, aynı zamanda modelin istatistiksel güvenilirliğini incelemektir. Bu doğrultuda Bernoulli dağılımı, Binom dağılımı, Normal dağılım, Merkezi Limit Teoremi, güven aralıkları ve hipotez testleri gibi istatistiksel kavramlar uygulanmıştır.

Bu proje kapsamında aşağıdaki sorulara cevap aranmıştır:

- Oluşturulan model kredi kartı dolandırıcılığını başarılı şekilde tespit edebilmekte midir?
- Model performansı istatistiksel olarak güvenilir midir?
- Accuracy değeri yalnızca şansa bağlı olarak mı oluşmuştur?
- Veri setindeki dengesizlik model sonuçlarını nasıl etkilemektedir?
- Cross-validation sonuçları normal dağılıma yaklaşmakta mıdır?

Bu proje sayesinde hem makine öğrenmesi hem de istatistiksel modelleme birlikte değerlendirilmiş ve gerçek dünya problemlerinde istatistiksel düşünmenin önemi gösterilmiştir

2.VERİ KEŞFİ VE ÖN İŞLEME

Veri bilimi projelerinde en önemli aşamalardan biri veri keşfi sürecidir. Veri setinin yapısını anlamadan oluşturulan modeller çoğu zaman güvenilir sonuçlar vermez.

Bu bölümde veri seti detaylı şekilde incelenmiş, eksik veriler kontrol edilmiş, temel istatistikler hesaplanmış ve görselleştirmeler yapılmıştır

Kullanılan Python Kütüphaneleri

```
#Kullanılan Python Kütüphaneleri
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import confusion_matrix
from sklearn.metrics import classification_report
from sklearn.metrics import accuracy_score
from sklearn.metrics import precision_score
from sklearn.metrics import recall_score
from sklearn.metrics import f1_score
from scipy import stats
```

Veri Setinin Yüklenmesi

```
#Veri Setinin Yüklenmesi
credit_df = pd.read_csv("creditcard.csv")
```

Eksik Veri Kontrolü

```
credit_df.isnull().sum()
```

Veri setinde eksik veri bulunmadığı görülmüştür. Bu durum modelleme süreci açısından avantaj sağlamaktadır

Temel Betimsel İstatistikler

```
credit_df.describe()
```

Betimsel istatistikler incelendiğinde özellikle Amount değişkeninde yüksek varyans olduğu görülmektedir. Maksimum işlem miktarı oldukça yüksektir. Bu durum veri setinde outlier değerlerin bulunduğunu göstermektedir.

Fraud ve Normal İşlem Dağılımı

```
#Fraud ve Normal İşlem Dağılımı
credit_df['Class'].value_counts()
```

Sonuç:

- Normal işlem sayısı: 284.315
- Fraud işlem sayısı: 492

Bu dağılım veri setinin ciddi şekilde dengesiz olduğunu açıkça göstermektedir.

Sınıf Dağılımı Görselleştirmesi

```
#Sınıf Dağılımı Görselleştirmesi
sns.countplot(x='Class', data=credit_df)
plt.title("Fraud ve Normal İşlem Dağılımı")
plt.show()
```


Amount Değişkeninin İncelenmesi

```
#Amount Değişkeninin İncelenmesi
sns.histplot(credit_df['Amount'], bins=50)
plt.title("Transaction Amount Histogram")
plt.show()
```

Histogram grafiği incelendiğinde (son kısımda grafik çıktı olarak verilmiştir.) Amount değişkeninin sağa çarpık bir dağılıma sahip olduğu gözlemlenmiştir. Büyük miktartlı işlemler daha seyrek.

Korelasyon Analizi

```
#Korelasyon Analizi
plt.figure(figsize=(14,10))
sns.heatmap(credit_df.corr(), cmap='coolwarm')
plt.title("Correlation Matrix")
plt.show()
```



Korelasyon matrisi incelendiğinde bazı PCA bileşenlerinin Fraud işlemler ile daha yüksek ilişkiye sahip olduğu görülmektedir.

3. İSTATİSTİKSEL TEMELLER VE METODOLOJİ

Bu projede kullanılan yöntemler yalnızca makine öğrenmesi tekniklerinden oluşmamaktadır. Aynı zamanda istatistiksel modelleme ve olasılık teorisi de yoğun şekilde kullanılmıştır. Kullanılan dağılımlar:

Bernoulli Dağılımı

Her işlem için modelin tahmini iki farklı sonuçtan oluşmaktadır: 1- Doğru tahmin 2-Yanlış tahmin. Bu nedenle her tahmin Bernoulli dağılımı ile modellenebilir.

Binom Dağılımı

Test setindeki toplam doğru tahmin sayısı Binom dağılımı ile modellenebilir.

Normal Dağılım ve Merkezi Limit Teoremi

5-Fold Cross Validation sonucunda elde edilen accuracy değerleri Merkezi Limit Teoremi nedeniyle yaklaşık normal dağılıma yaklaşmaktadır.

6 Merkezi Limit Teoremi'ne göre örneklem sayısı arttıkça örneklem ortalamalarının dağılımı normal dağılıma yaklaşır. Bu nedenle cross-validation sonuçlarının: $X \sim N(\mu, \sigma^2/n)$ şeklinde modellenebileceği kabul edilmiştir.

Güven Aralıkları

Model accuracy değeri için %95 güven aralığı hesaplanmıştır.

Formül: $CI = \bar{x} \pm z * (s / \sqrt{n})$

Burada:

- $\bar{x} \rightarrow$ accuracy ortalaması
- $s \rightarrow$ standart sapma
- $n \rightarrow$ fold sayısı
- $z = 1.96$

Hipotez Testi

Bu projede aşağıdaki hipotez testi uygulanmıştır:

H_0 : Model accuracy ≤ 0.90

H_1 : Model accuracy > 0.90

Amaç modelin %90 başarı seviyesinin üzerinde olup olmadığını test etmektir.

4.MODELLEME SÜRECİ

Bu projede sınıflandırma modeli olarak Logistic Regression algoritması kullanılmıştır.

Veri Ayrıştırma

Öncelikle veri seti eğitim ve test verisi olarak ikiye ayrılmıştır.

```
#Veri Ayrıştırma
X = credit_df.drop('Class', axis=1)
y = credit_df['Class']
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=42,
    stratify=y
)
```

Burada stratify parametresi kullanılarak Fraud oranının train ve test setlerinde korunması sağlanmıştır.

Model Eğitimi

```
#Model Eğitimi
model = LogisticRegression(max_iter=1000)
model.fit(X_train, y_train)
```

Tahmin İşlemi

```
#Tahmin İşlemi
y_pred = model.predict(X_test)
```

Accuracy Hesaplama

```
#Accuracy Hesaplama
accuracy = accuracy_score(y_test, y_pred)
print(accuracy)
```

```
... 0.9981098109810981
```

Bu değer ilk bakışta oldukça yüksek görünmektedir. Ancak veri setinin dengesiz olması nedeniyle accuracy metriği tek başına yeterli değildir

Confusion Matrix

```
#Confusion Matrix
cm = confusion_matrix(y_test, y_pred)
print(cm)
```

```
... [[11067  12]
     [    9  22]]
```

Bu sonuç aşağıdaki anlamlara gelmektedir:

- True Negative: 11067
- False Positive: 12
- False Negative: 9
- True Positive: 22

Fraud işlemleri tespit etmek kritik olduğu için False Negative değerleri oldukça önemlidir.

Precision Hesaplama

```
precision = precision_score(y_test, y_pred)
```

Precision değeri modelin Fraud dediği işlemlerin gerçekten Fraud olma oranını göstermektedir.

Recall Hesaplama

```
recall = recall_score(y_test, y_pred)
```

Recall değeri gerçek fraud işlemlerinin ne kadarının yakalandığını göstermektedir.

F1-Score

```
#F1-Score  
f1 = f1_score(y_test, y_pred)
```

F1-score precision ve recall değerlerinin harmonik ortalamasıdır.

5.PERFORMANS ANALİZİ

Accuracy Analizi

Model yaklaşık %99.91 accuracy elde etmiştir. Ancak veri setinin büyük çoğunluğu normal işlem olduğu için bu değer yanıltıcı olabilir. Bu nedenle precision ve recall metrikleri kritik öneme sahiptir.

Precision Analizi

Precision değeri fraud olarak tahmin edilen işlemlerin ne kadarının gerçekten fraud olduğunu göstermektedir.

Örnek precision değeri:

Precision $\approx$ 0.81

Bu sonuç modelin fraud olarak işaretlediği işlemlerin %81'inin gerçekten fraud olduğunu göstermektedir.

Recall Analizi

Recall değeri gerçek fraud işlemlerinin ne kadarının yakalandığını gösterir.

Örnek recall değeri:

Recall $\approx$ 0.62

Bu sonuç fraud işlemlerin yaklaşık %62'sinin başarıyla tespit edildiğini göstermektedir.

Finans sektöründe recall metriği oldukça önemlidir. Çünkü fraud işlemlerin kaçırılması büyük maddi kayıplara neden olabilir.

F1-Score Analizi

F1-score precision ve recall arasında denge kurar.

Örnek F1-score:

F1 $\approx$ 0.70

Bu sonuç modelin genel olarak dengeli bir performans gösterdiğini ifade etmektedir.

ROC Eğrisi ve AUC

ROC eğrisi farklı threshold değerlerinde model performansını göstermektedir.

```
#ROC Eğrisi ve AUC
from sklearn.metrics import roc_curve
from sklearn.metrics import roc_auc_score
auc_score = roc_auc_score(y_test, y_pred)
print(auc_score)
```

... 0.8542971445542132

AUC değerinin 1'e yakın olması modelin başarılı olduğunu göstermektedir.

6. HİPOTEZ TESTLERİ VE GÜVEN ARALIKLARI

Hipotez Testi

Hipotezler:

H_0 : Accuracy $\leq$ 0.90

H_1 : Accuracy $>$ 0.90

Bu testin amacı model performansının gerçekten yüksek olup olmadığını belirlemektir.

Z-Testi Hesaplaması

Örnek:

- Accuracy = 0.9991
- Threshold = 0.90
- Test örnek sayısı = 56962

Standart hata:

$$SE = \sqrt{p(1-p)/n}$$

```
#Z-Testi Hesaplaması
p_hat = accuracy
p0 = 0.90
n = len(y_test)
se = np.sqrt((p0 * (1-p0))/n)
z = (p_hat - p0) / se
```

Örnek Z değeri: $Z \approx 71$

Bu değer oldukça yüksektir.

p-değeri

```
#p-değeri
p_value = 1- stats.norm.cdf(z)
```

Örnek sonuç:

p-value < 0.0001

Bu nedenle H_0 reddedilir.

Sonuç olarak model performansının %90 seviyesinden anlamlı şekilde yüksek olduğu söylenebilir.

Güven Aralığı

Accuracy için %95 güven aralığı hesaplanmıştır.

```
confidence_interval = stats.norm.interval(
    0.95,
    loc=accuracy,
    scale=stats.sem(cv_scores)
)
print(confidence_interval)

... (np.float64(0.9540335495610167), np.float64(1.0421860724011796))
```

Örnek sonuç: [0.9540, 1.0421]

Bu aralık model performansının oldukça stabil olduğunu göstermektedir.

7. CROSS VALIDATION VE MERKEZİ LİMİT TEOREMİ

Bu projede 5-Fold Cross Validation uygulanmıştır.

5-Fold Cross Validation

```
#Cross-Validation
from sklearn.model_selection import cross_val_score
cv_scores = cross_val_score(
    model,
    X,
    y,
    cv=5,
    scoring='accuracy'
)
```

Örnek sonuç

```
[0.88541854 0.99666967 0.99720972 0.99909991 0.99837984]
/usr/local/lib/python3.12/dist-packages/sklearn/model_selection/_logit
```

Ortalama Accuracy

```
#Ortalama Accuracy
cv_scores.mean()

... np.float64(0.9753555355535554)
```

Standart Sapma

```
#Standart Sapma
cv_scores.std()

... np.float64(0.04497660341490895)
```


Bu düşük standart sapma modelin farklı veri parçalarında benzer performans gösterdiğini ifade etmektedir.

Merkezi Limit Teoremi Yorumu

Cross-validation accuracy değerleri yaklaşık normal dağılım göstermektedir. Bu durum Merkezi Limit Teoremi ile açıklanabilir. Fold sayısı arttıkça accuracy ortalamalarının dağılımı normale yaklaşmaktadır.

Histogram Analizi

```
#Histogram Analizi
sns.histplot(cv_scores, kde=True)
plt.title("Cross Validation Accuracy Distribution")
plt.show()
```




Histogram grafiği incelendiğinde dağılımın yaklaşık simetrik olduğu görülmektedir.

8. GÖRSELLEŐTİRMELER VE BULGULAR

Fraud İőlem Dağılımı


Fraud işlemlerin veri setindeki oranı oldukça düşüktür. Bu durum grafik üzerinde net şekilde görölmektedir.



Grafik incelendiğinde normal işlemlerin veri setinin büyük çoğunluğunu oluşturduğu görölmektedir. Fraud işlemler ise çok küçük bir bölümde yer almaktadır. Bu durum veri setinin ciddi şekilde dengesiz olduğunu göstermektedir. Bu grafik veri setinin neden zor bir problem olduğunu göstermektedir.

Amount Histogramı

İşlem miktarlarının dağılımı sağa çarpık yapıdadır.




Histogram incelendiğinde küçük miktarlı işlemlerin yoğun olduğu görülmektedir. Büyük miktarlı işlemler ise daha az sayıdadır. Finansal verilerde bu tarz sağa çarpık dağılımlar oldukça yaygındır. Büyük miktarlı işlemler nadirdir ancak fraud işlemler belirli miktar aralıklarında yoğunlaşabilmektedir.

Confusion Matrix Heatmap

```
#Confusion Matrix  
sns.heatmap(cm, annot=True, fmt='d')  
plt.title("Confusion Matrix")  
plt.show()
```


Bu grafik modelin doğru ve yanlış tahmin sayılarını görsel şekilde göstermektedir



True Negative değerlerinin oldukça yüksek olması veri setindeki normal işlemlerin fazla olmasından kaynaklanmaktadır. Fraud işlemlerinin önemli bir kısmı doğru tespit edilmiştir ancak bazı fraud işlemleri kaçırılmıştır.

ROC Eğrisi


ROC eğrisi modelin farklı threshold değerlerindeki performansını göstermektedir.



ROC eğrisinin sol üst köşeye yakın olması modelin başarılı sınıflandırma yaptığını göstermektedir. AUC değerinin yüksek olması fraud ve normal işlemlerin başarılı şekilde ayrıldığını ifade etmektedir. AUC değerinin yüksek olması modelin sınıfları başarılı şekilde ayırdığını göstermektedir.

Cross Validation Histogramı

Cross-validation accuracy değerlerinin histogramı yaklaşık normal dağılım göstermektedir.



Histogramın yaklaşık simetrik yapıda olması Merkezi Limit Teoremi ile uyumludur. Fold sonuçlarının birbirine yakın olması modelin stabil çalıştığını göstermektedir. Bu durum Merkezi Limit Teoremi ile uyumludur.

9. TARTIŞMA

Bu projede kredi kartı dolandırıcılığı problemi üzerinde istatistiksel ve makine öğrenmesi temelli analizler gerçekleştirilmiştir.

Elde edilen sonuçlar Logistic Regression modelinin genel olarak başarılı performans gösterdiğini ortaya koymuştur. Accuracy değerinin oldukça yüksek olması ilk bakışta modelin mükemmel performans gösterdiği izlenimini oluşturmaktadır. Ancak veri setinin dengesiz yapısı nedeniyle accuracy metriğinin tek başına yeterli olmadığı görülmüştür.

Bu nedenle precision, recall ve F1-score gibi ek metrikler incelenmiştir. Özellikle recall değerinin fraud işlemleri yakalama açısından kritik olduğu anlaşılmıştır.

Modelin bazı fraud işlemleri kaçırdığı görülmektedir. Finans sektöründe bu durum önemli riskler oluşturabilir. Bu nedenle gelecekte daha gelişmiş modeller kullanılabilir.

Örneğin:

- Random Forest
- XGBoost
- Neural Networks
- SMOTE ile oversampling
- Ensemble yöntemleri kullanılarak model performansı artırılabilir.

Bu projede ayrıca istatistiksel hipotez testleri uygulanmış ve model performansının rastgele oluşmadığı gösterilmiştir.

Cross-validation sonuçlarının düşük varyansa sahip olması modelin stabil çalıştığını göstermektedir.

Ancak proje kapsamında bazı sınırlamalar bulunmaktadır:

- PCA nedeniyle özelliklerin gerçek anlamları bilinmemektedir.
- Veri seti eski işlemlerden oluşmaktadır.
- Gerçek zamanlı sistem davranışı incelenmemiştir.
- Veri seti aşırı dengesizdir.

Tüm bu sınırlamalara rağmen proje sonuçları istatistiksel olarak anlamlı ve güvenilirlerdir.

10. SONUÇ

Bu projede “Credit Card Fraud Detection” veri seti kullanılarak bir makine öğrenmesi modelinin performansı istatistiksel açıdan değerlendirilmiştir.

Projede Logistic Regression algoritması kullanılmış ve model performansı accuracy, precision, recall, F1 score ve AUC gibi metriklerle analiz edilmiştir.

Elde edilen sonuçlara göre:

- Model yüksek accuracy değeri elde etmiştir.
- Veri seti ciddi derecede dengesizdir.
- Accuracy metriği tek başına yeterli değildir.
- Recall metriği fraud tespiti açısından kritik öneme sahiptir.

- Hipotez testleri model performansının istatistiksel olarak anlamlı olduğunu göstermektedir.
- Cross-validation sonuçları modelin stabil çalıştığını göstermektedir.
- Merkezi Limit Teoremi accuracy dağılımı üzerinde gözlemlenmiştir.

Bu proje sayesinde istatistiksel yöntemlerin makine öğrenmesi projelerinde ne kadar önemli olduğu görülmüştür.

Gerçek dünya problemlerinde yalnızca model oluşturmak yeterli değildir. Aynı zamanda model sonuçlarının güvenilirliği, istatistiksel anlamlılığı ve genellenebilirliği de analiz edilmelidir.

Sonuç olarak bu proje veri bilimi, istatistik ve makine öğrenmesi kavramlarını birlikte kullanarak kredi kartı dolandırıcılığı probleminin başarılı şekilde analiz edilmesini sağlamıştır.

11. KAYNAKÇA

1. Kaggle – Credit Card Fraud Detection Dataset: <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>
2. Scikit-learn Documentation: <https://scikit-learn.org/stable/documentation.html>
3. NumPy Documentation: <https://numpy.org/doc/>
4. Pandas Documentation: <https://pandas.pydata.org/docs/>
5. SciPy Stats Documentation: <https://docs.scipy.org/doc/scipy/reference/stats.html>
6. Matplotlib Documentation: <https://matplotlib.org/stable/gallery/>